

Sprawozdanie 1

Paweł Maciocha

1 Wprowadzenie

W niniejszym sprawozdaniu zajmiemy się wyceną opcji europejskich *call* oraz *put*. W tym celu posłużymy się modelami dyskretnymi, w których losowość wyrażana jest poprzez wystąpienie skończonej liczby możliwych scenariuszy.

Zakłada się przy tym, że rynek jest wielookresowy tzn. cena akcji zmienia się w chwilach $t = 1, 2, \dots, T$ gdzie T to czas wygaśnięcia instrumentu. Najprostszym modelem wyceny opcji jest model dwumianowy, w którym to w każdym okresie może wystąpić jedno z dwóch zdarzeń - przyrost lub spadek ceny akcji. Dokładniej, jeśli w momencie t cena akcji wynosi S_t , to w momencie $t+1$ może wzrosnąć z prawdopodobieństwem p do $S_t u$, gdzie $u > 1$, lub spaść do $S_t d$, gdzie $0 < d < 1$.

Powyższy model można przedstawić graficznie za pomocą drzewa. Więcej o przedstawieniu graficznym przeczytać można w (...) strona 1. Podstawowym zagadnieniem związanym z modelem dwumianowym jest dobranie takich parametrów u , d oraz p , aby otrzymać jak najlepsze przybliżenie możliwych ruchów cen akcji.

2 Kalibracja modelu

W celu wyznaczenia parametrów u , d oraz p przyrównuje się średnią i wariancję ceny z końca okresu modelu dwumianowego do średniej i wariancji w modelu Blacka-Scholesa. Parametry spełniają wtedy następujące równania:

$$pu + (1 - p)d = e^{(r-q)\Delta t} \quad (1)$$

$$pu^2 + (1 - p)d^2 = e^{2(r-q+\sigma^2/2)\Delta t}. \quad (2)$$

Z powyższego otrzymujemy,

$$e^{(r-q)\Delta t}(u + d) - du = e^{2(r-q+\sigma^2/2)\Delta t}, \quad (3)$$

gdzie Δt jest długością okresu.

Aby jednoznacznie wyznaczyć u , d i p potrzebne jest dodatkowe równanie. Można je określić korzystając z modelu Coxa-Rossa-Rubinsteina lub Jarrowa-Ruda. Pierwszy z nich zakłada, że $ud = 1$, a drugi ustala wartość $p = \frac{1}{2}$.

3 Symulacje

W tej sekcji spróbujemy porównać oba modele w oparciu o symulacje, które przeprowadzimy w języku *Python*. Kod programu prezentuje się w sposób następujący

```
def Binomial_CRR(S, K, T, r, sigma, PutCall, n):
    dt = T/n
    u = np.exp(sigma*np.sqrt(dt))
    d = 1./u
    p = (np.exp(r*dt)-d) / (u-d)
    return Binomial_Body_Function(S, K, dt, r, PutCall, n, u, d, p)
```

```

def Binomial_JR(S, K, T, r, sigma, PutCall, n):
    dt = T/n
    u = np.exp((r - sigma**2/2)*dt + sigma*np.sqrt(dt))
    d = np.exp((r - sigma**2/2)*dt - sigma*np.sqrt(dt))
    p = 0.5
    return Binomial_Body_Function(S, K, dt, r, PutCall, n, u, d, p)

def Binomial_Body_Function(S, K, dt, r, PutCall, n, u, d, p):
    stockvalue = np.zeros((n+1,n+1))
    stockvalue[0,0] = S
    for i in range(1,n+1):
        stockvalue[i,0] = stockvalue[i-1,0]*u
        for j in range(1,i+1):
            stockvalue[i,j] = stockvalue[i-1,j-1]*d

    optionvalue = np.zeros((n+1,n+1))
    for j in range(n+1):
        if PutCall=="Call":
            optionvalue[n,j] = max(0, stockvalue[n,j]-K)
        elif PutCall=="Put":
            optionvalue[n,j] = max(0, K-stockvalue[n,j])

    for i in range(n-1,-1,-1):
        for j in range(i+1):
            if PutCall=="Put":
                optionvalue[i,j] = max(0, np.exp(-r*dt)*
                    (p*optionvalue[i+1,j] + (1-p)*optionvalue[i+1,j+1]))
            elif PutCall=="Call":
                optionvalue[i,j] = max(0, np.exp(-r*dt)*
                    (p*optionvalue[i+1,j] + (1-p)*optionvalue[i+1,j+1]))

    return optionvalue[0,0]

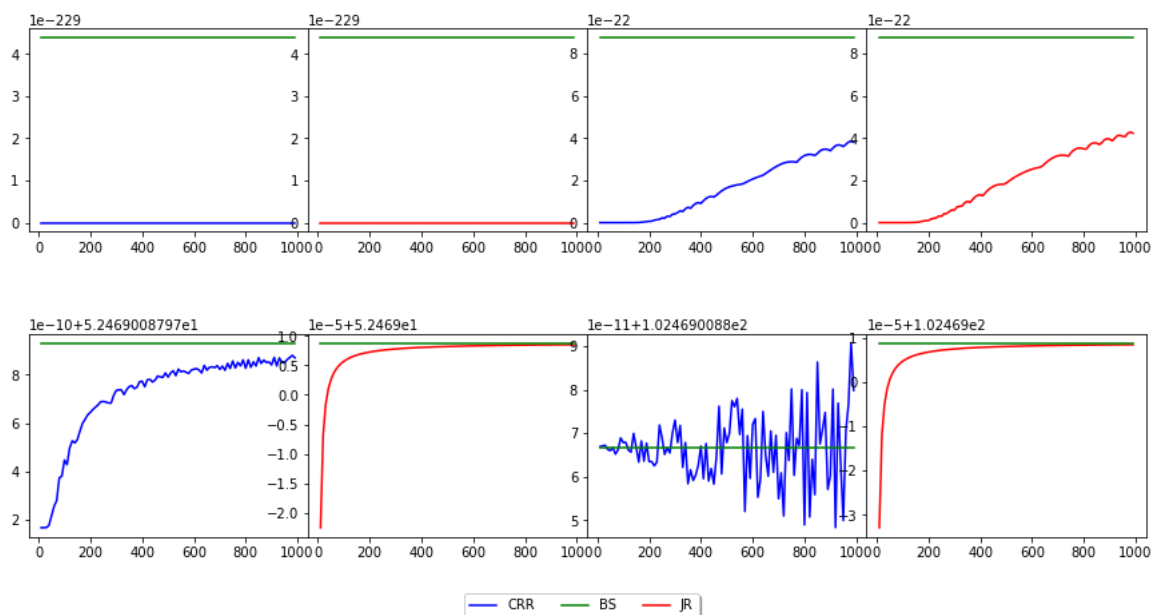
```

Rozważamy $t = 5, 10, \dots, 1000$. Z racji iż przestrzeń parametrów jest nieskończona musimy się na jakiś zdecydować. Zatem niech

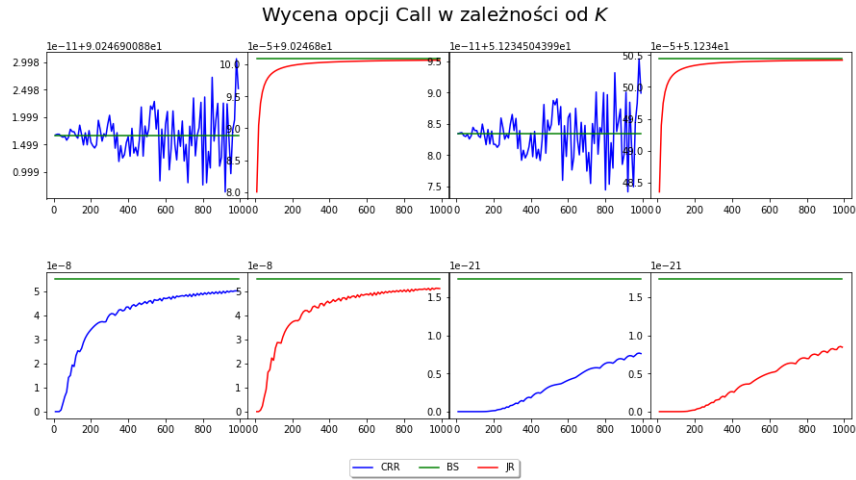
$$S = 100, \quad K = 100, \quad T = \frac{1}{2}, \quad r = 0.05, \quad \sigma = 0.1. \quad (4)$$

Będziemy badać szybkość zbieżności cen modeli do ceny Blacka-Scholesa (BS). Gdy $S \in \{10, 50, 150, 200\}$.


Wycena opcji Call w zależności od S




Z powyższego rysunku zauważyć możemy, że model JR cechuje z jednej strony większą stabilnością z drugiej natomiast obciążony jest większym błędem szczególnie dla małych n . Na kolejnych rysunkach rozważamy $K \in \{10, 50, 150, 200\}$, $T \in \{1, 0.5, 1/12\}$, $r \in \{0, 0.05, 0.1, 0.15\}$ oraz $\sigma \in \{0.01, 0.1, 1, 10\}$.



W przypadku gdy zmienną jest K sytuacja jest analogiczna do tej gdy zmienną jest S .

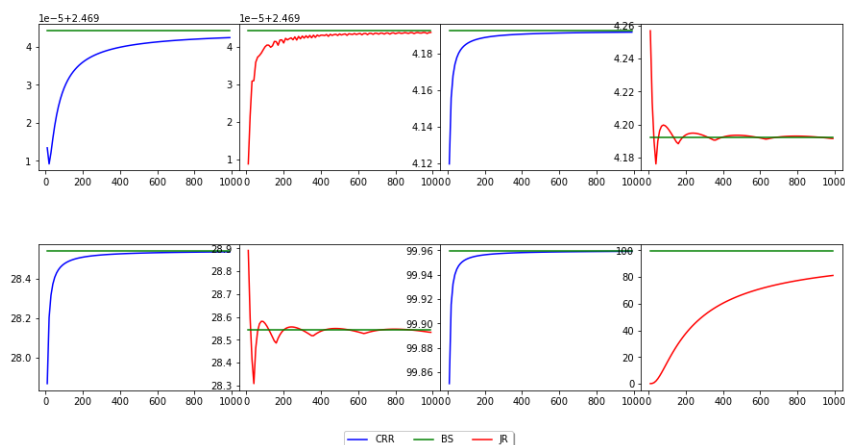


Zauważmy, że wraz ze wzrostem argumentu T model JR się stabilizuje, jest on dokładniejszy od modelu CRR, natomiast jest mniej stabilny. Być może, że wraz ze wzrostem parametru T (lub n) się stabilizuje się całkowicie.



Widzimy, że wraz ze wzrostem spoty procentowej model JR traci na stabilności ale jednocześnie jego dokładność względem CRR się zwiększa.

Wycena opcji Call w zależności od σ



Zauważyć możemy, że w przypadku gdy σ przyjmuje wartości bardzo małe to model JR jest bezdyskusyjnie lepszy pomimo mniejszej stabilności. Jednakże gdy σ przyjmuje wartości coraz to większe model JR staje się coraz gorszy.

Nie będziemy porównywać modeli dla opcji *put*. Wnioski nie będą się wiele różnić z faktu iż algorytmy wyznaczające ceny instrumentów różnią się tylko i wyłącznie ceną wypłaty, a zatem nie może to znacznie wpłynąć na stabilność czy zbieżność do ceny BS omawianych modeli. Z wykresami dla opcji *put* można się zapoznać na końcu artykułu.

4 Wpływ parametrów u i d na wycenę

Poprzednio przyjmowaliśmy,

$$u = \exp(\sigma\sqrt{dt}), \quad d = \frac{1}{u}, \quad p = \frac{\exp(rdt) - d}{u - d}, \quad (5)$$

$$u = \exp\{(r - \frac{\sigma^2}{2})dt + \sigma\sqrt{dt}\}, \quad d = \exp\{(r - \frac{\sigma^2}{2})dt - \sigma\sqrt{dt}\}, \quad p = \frac{1}{2} \quad (6)$$

odpowiednio dla CRR oraz JR. Niech teraz

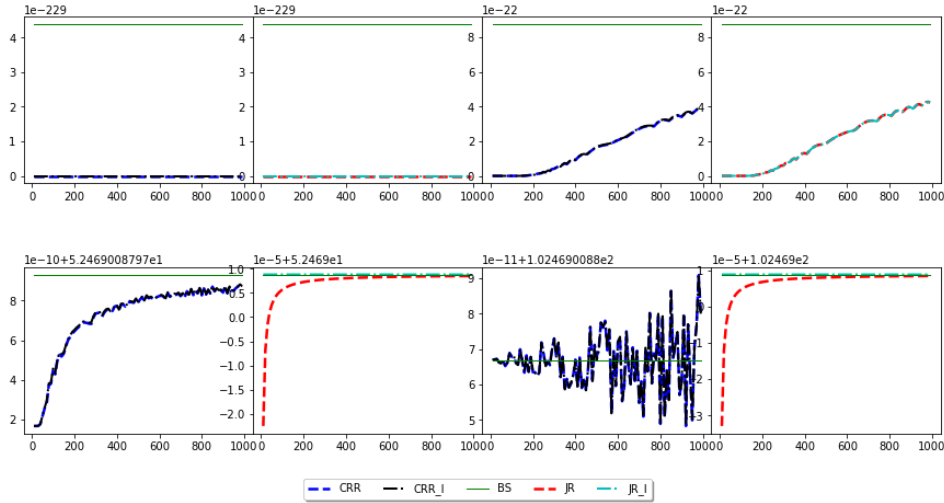
$$u_+/d_- = \frac{1}{2} \left((e^{rdt+\sigma^2 dt} + e^{-rdt}) \pm \sqrt{(e^{rdt+\sigma^2 dt} + e^{-rdt})^2 - 4} \right), \quad (7)$$

$$u_+/d_- = e^{rdt} (1 \pm \sqrt{e^{\sigma^2 dt} - 1}), \quad (8)$$

dla CRR oraz JR, p dane jest przez takie same wzory jak poprzednio (z uwzględnieniem nowych wartości u i d).

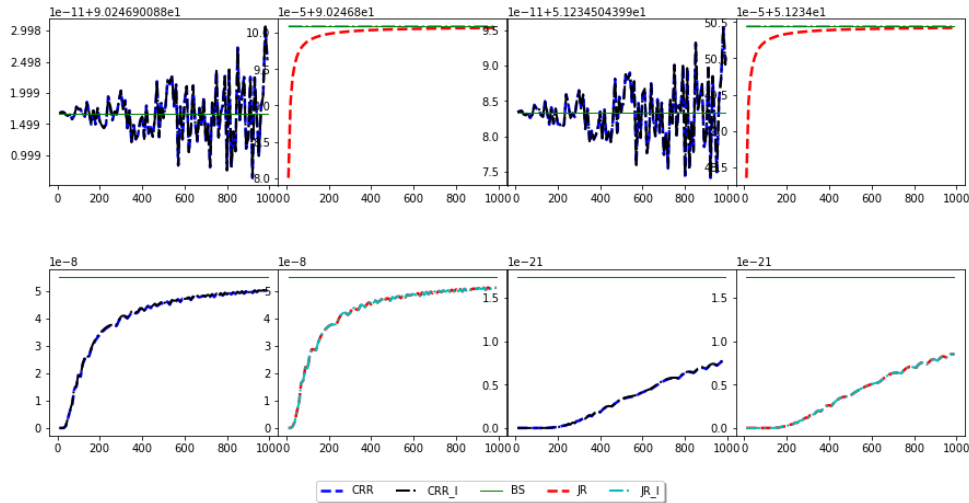
Ponownie przeprowadzając symulacje porównamy modele ze starym zestawem zmiennych oraz te z nowym. Wartości parametrów S, K, T, r, σ przyjmujemy takie jak poprzednio.

Porównanie wyceny opcji Call dla par. S




Poprawę obserwujemy przy $S = 150, 200$ dla modelu JR widzimy, że wartość jest bardzo dokładne dla małych n .

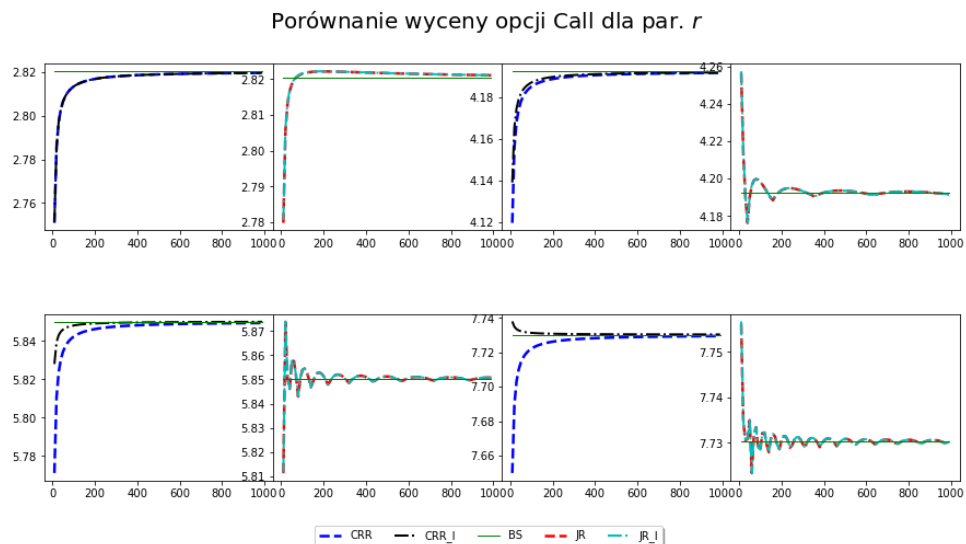
Porównanie wyceny opcji Call dla par. K



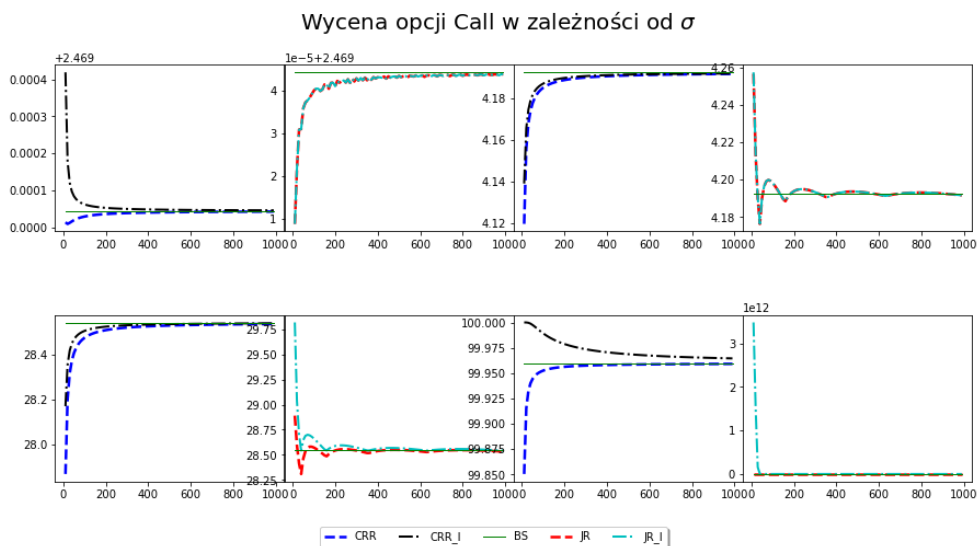
Zauważmy zależność, model JR z nowymi parametrami poprzednio poprawiał dokładność gdy początkowa cena akcji była duża, teraz dokładność jest lepsza gdy cena wykonania jest względnie mała.



Widoczną poprawę odnotować możemy dla modelu CRR gdy $T = 1$ oraz $1/2$. Być może im krótszy okres inwestycji tym lepiej sprawuje się model CRR z nowymi parametrami.



Ponownie lepsze wyniki uzyskujemy dla CRR w przypadku modelu JR nie widać poprawy. Odnajemy, że przy zerowej stopie procentowej poprawy nie ma.



Dla parametru σ wyniki nie są aż tak jednoznaczne.